Nhận diện và phân tích giá xe hơi ở Việt Nam

Phạm Trọng Nghĩa[1], Trần Công Vinh[1], and Trần Quang Duy[1]

Học phần PPR501, FSB-MSA
Giảng viên hướng dẫn: Nguyễn Xuân Sâm

Abstract. Báo cáo trình bày dự án phân tích dữ liệu ô tô tại Việt Nam thông qua ba hướng tiếp cận: Linear Regression để khảo sát và ước lượng giá xe, Convolutional Neural Network (CNN) để phân loại ảnh xe, và Vision Transformer (ViT) như một hướng tiếp cận dự kiến cho bài toán phân loại ảnh. Phần phân tích giá sử dụng dữ liệu rao bán xe, chuyển đổi giá từ các đơn vị "Tỷ" và "Triệu" sang triệu đồng, sau đó khảo sát mối quan hệ giữa năm sản xuất và giá xe. Ứng dụng Streamlit hỗ trợ xem dữ liệu, lựa chọn biến đầu vào và mục tiêu, huấn luyện mô hình, trực quan hóa kết quả và thử dự đoán. Phần phân loại ảnh sử dụng bộ dữ liệu gồm bảy nhóm xe. Notebook hiện có ghi nhận accuracy trên tập test khoảng 68,76% và loss khoảng 1,1721 sau 20 epoch. Đối với ViT, báo cáo đề xuất quy trình thực nghiệm nhằm khảo sát khả năng áp dụng Transformer vào phân loại ảnh xe và tạo cơ sở so sánh với CNN. Tuy nhiên, ViT chưa được triển khai trong phiên bản hiện tại nên chưa có kết quả thực nghiệm. Báo cáo phân tích các giới hạn về tiền xử lý, đánh giá mô hình và khả năng tái lập, đồng thời đề xuất các bước hoàn thiện thực nghiệm trong tương lai.

Keywords: Phân tích dữ liệu · Ô tô · Linear Regression · CNN · Vision Transformer · Machine Learning

1 Giới thiệu

Thị trường ô tô có thể được khảo sát thông qua dữ liệu rao bán và hình ảnh phương tiện. Dữ liệu có cấu trúc cung cấp thông tin về giá, năm sản xuất, số kilomet đã đi và các thuộc tính của xe. Trong khi đó, hình ảnh cung cấp thông tin trực quan có thể được sử dụng để nhận diện nhóm xe.

Dự án "PPR501 Car Analysis" tập trung vào hai nhóm bài toán chính. Nhóm thứ nhất là phân tích và ước lượng giá xe từ dữ liệu có cấu trúc. Nhóm thứ hai là phân loại hình ảnh xe bằng các mô hình học sâu. Trong nhóm bài toán thị giác máy tính, CNN là phương pháp đã được triển khai, còn Vision Transformer (ViT) được đề xuất như một hướng mở rộng để nghiên cứu khả năng sử dụng cơ chế self-attention trong phân loại ảnh xe.

Mục tiêu của dự án là xây dựng các công cụ minh họa có thể tương tác, giúp người dùng quan sát dữ liệu, thử dự đoán và tìm hiểu cách áp dụng các phương pháp Machine Learning vào bài toán ô tô. Dự án đồng thời xem xét các giới hạn của quy trình huấn luyện và đánh giá để xác định những cải tiến cần thiết.

Các câu hỏi nghiên cứu được xác định như sau:

RQ1. Linear Regression có thể được sử dụng như một baseline để khảo sát mối quan hệ giữa năm sản xuất và giá xe như thế nào?
RQ2. CNN có khả năng phân loại hình ảnh xe thuộc bảy nhóm đã xác định ở mức độ nào theo kết quả hiện có?
RQ3. Vision Transformer có thể được triển khai để giải quyết cùng bài toán phân loại ảnh xe, và cần những điều kiện thực nghiệm nào để so sánh với CNN?

Trong phạm vi phiên bản hiện tại, hai phương pháp Linear Regression và CNN đã có phần triển khai. ViT mới ở giai đoạn đề xuất, do đó câu hỏi RQ3 chưa được trả lời bằng kết quả thực nghiệm.

2 Cơ sở lý thuyết và nghiên cứu liên quan

2.1 Linear Regression

Linear Regression là phương pháp hồi quy có giám sát được sử dụng để mô hình hóa mối quan hệ giữa biến đầu vào và biến mục tiêu. Với một biến đầu vào, mô hình giả định mối quan hệ tuyến tính giữa đặc trưng và giá trị cần dự đoán.

Ưu điểm của phương pháp là dễ triển khai, dễ diễn giải và phù hợp để xây dựng baseline. Tuy nhiên, giá xe chịu ảnh hưởng của nhiều yếu tố và các mối quan hệ này không nhất thiết là tuyến tính. Do đó, mô hình sử dụng riêng năm sản xuất không thể đại diện đầy đủ cho toàn bộ quá trình hình thành giá xe.

2.2 Convolutional Neural Network

CNN là kiến trúc mạng nơ-ron thường được sử dụng trong xử lý ảnh. Các lớp convolution học đặc trưng không gian từ ảnh, trong khi pooling giảm kích thước biểu diễn và hỗ trợ xây dựng đặc trưng ở mức cao hơn. Các lớp fully connected sử dụng đặc trưng đã trích xuất để dự đoán nhãn.

Trong dự án này, CNN được sử dụng làm mô hình phân loại ảnh xe đã triển khai. Kết quả của mô hình là cơ sở ban đầu để đánh giá khả năng nhận diện bảy nhóm xe.

2.3 Vision Transformer

Vision Transformer được giới thiệu bởi Dosovitskiy và cộng sự, áp dụng kiến trúc Transformer cho bài toán phân loại ảnh. Thay vì chỉ sử dụng các phép tích chập, ViT chia ảnh thành các patch, chuyển chúng thành vector biểu diễn và xử lý chuỗi vector thông qua các Transformer Encoder.

Cơ chế self-attention cho phép mô hình học quan hệ giữa các patch trong ảnh. Tuy nhiên, hiệu quả thực tế phụ thuộc vào kiến trúc, dữ liệu, trọng số khởi tạo và cấu hình huấn luyện. ViT không mặc nhiên tốt hơn CNN trong mọi bài toán, đặc biệt khi dữ liệu huấn luyện có quy mô hạn chế.

Trong phạm vi dự án, ViT được đề xuất để phân loại cùng bộ dữ liệu ảnh xe với CNN. Việc sử dụng trọng số pretrained và fine-tuning là một phương án cần khảo sát nhằm giảm nhu cầu huấn luyện từ đầu.

3 Dữ liệu và tiền xử lý

3.1 Dữ liệu giá xe

Dự án sử dụng tệp `car-price.csv` lấy từ Kaggle [**?**]. Theo thông tin hiện có của dự án, tệp gồm 15.442 dòng và 17 cột. Các thuộc tính bao gồm giá, năm sản xuất, số kilomet đã đi, tình trạng, xuất xứ, kiểu dáng, động cơ và các thông tin khác trong tin đăng. README của dự án mô tả dữ liệu bao phủ giai đoạn 1990–2023.

Giá xe được lưu dưới dạng văn bản có thể chứa đơn vị "Tỷ" và "Triệu". Để phục vụ phân tích số, giá được quy đổi về triệu đồng Việt Nam. Phần giá tính theo tỷ được nhân với 1.000 rồi cộng với phần giá tính theo triệu.

Quá trình tiền xử lý cần loại bỏ hoặc xử lý những dòng có giá không hợp lệ, giá trị thiếu và các trường hợp không thể chuyển đổi sang kiểu dữ liệu số. Các bước này cần được kiểm tra khi chạy lại để bảo đảm số lượng quan sát sử dụng trong mô hình là rõ ràng và có thể tái lập.

3.2 Dữ liệu ảnh xe

Bộ dữ liệu ảnh được lấy từ nguồn Kaggle [**?**]. Theo notebook hiện có, dữ liệu gồm 3.352 ảnh train và 813 ảnh test. Các thư mục con tương ứng với bảy nhãn:

- Audi;
- Hyundai Creta;
- Mahindra Scorpio;
- Rolls Royce;
- Swift;
- Tata Safari;
- Toyota Innova.

Notebook CNN đọc ảnh ở kích thước 256×256 và chuẩn hóa giá trị pixel về khoảng $[0, 1]$. Phép xoay ảnh và lật ngang được sử dụng để tăng cường dữ liệu huấn luyện.

Đối với hướng ViT, kích thước ảnh và phép chuẩn hóa cần được xác định theo cấu hình cụ thể của mô hình được chọn. Nếu sử dụng mô hình pretrained, cần áp dụng đúng quy trình tiền xử lý tương ứng với trọng số đó.

Trước khi thực hiện so sánh CNN và ViT, cần kiểm tra ảnh trùng lặp, sự nhất quán của nhãn và khả năng rò rỉ dữ liệu giữa các tập. Tập test cuối cùng cần được giữ độc lập với quá trình lựa chọn mô hình và siêu tham số.

4 Phương pháp

4.1 Ước lượng giá bằng Linear Regression

Script `linear_regression.py` sử dụng năm sản xuất làm biến đầu vào X và giá xe theo triệu đồng làm biến mục tiêu Y. Mô hình hồi quy tuyến tính được biểu diễn như sau:

$$\widehat{Y} = \beta_1 X + \beta_0, \tag{1}$$

trong đó β_1 là hệ số góc, β_0 là hệ số chặn và $\widehat{Y}$ là giá trị dự đoán.

Script hiện có tính RMSE và R^2 trên các quan sát đã được sử dụng để khớp mô hình, vẽ dữ liệu thực cùng đường hồi quy và minh họa dự đoán cho xe sản xuất năm 2022.

Ứng dụng Streamlit mở rộng khả năng tương tác bằng cách cho phép người dùng chọn cột đầu vào và cột mục tiêu. Các giá trị dạng văn bản được chuyển đổi sang số bằng cách trích xuất số đầu tiên trong chuỗi. Những dòng không chuyển đổi được sẽ bị loại khỏi dữ liệu dùng để huấn luyện.

Sau khi người dùng yêu cầu huấn luyện, ứng dụng hiển thị phương trình hồi quy, RMSE, R^2, biểu đồ và giao diện nhập giá trị để thử dự đoán. Cách chuyển đổi văn bản thành số hiện tại phục vụ mục đích minh họa; nó không thay thế quy trình mã hóa biến phân loại phù hợp.

4.2 Phân loại ảnh bằng CNN

Notebook `sources/CNN/main.ipynb` đọc ảnh từ các thư mục train và test, sau đó xây dựng mô hình CNN tuần tự. Kiến trúc được mô tả trong notebook gồm hai lớp convolution, mỗi lớp có 32 bộ lọc, xen kẽ với max pooling. Tiếp theo là lớp Flatten, hai lớp Dense có lần lượt 96 và 32 units, Dropout với tỷ lệ 0,30 và lớp đầu ra softmax gồm bảy units.

Mô hình sử dụng Adam optimizer, Sparse Categorical Crossentropy làm hàm mất mát và accuracy làm metric. Notebook huấn luyện mô hình trong 20 epoch.

Sau huấn luyện, notebook tính loss và accuracy trên tập được cấu hình là test, trực quan hóa các đường học và cung cấp giao diện Gradio cho phép người dùng tải ảnh lên để dự đoán. Giao diện sử dụng `share=True`, có thể tạo liên kết truy cập công khai trong thời gian server hoạt động. Vì vậy, cần thận trọng khi sử dụng với dữ liệu hoặc môi trường không được phép công khai.

4.3 Phân loại ảnh bằng Vision Transformer

ViT được đề xuất làm phương pháp thứ hai cho bài toán phân loại bảy nhóm ảnh xe. Phương pháp này chưa được triển khai trong phiên bản hiện tại của dự án; do đó, các nội dung dưới đây mô tả thiết kế thực nghiệm dự kiến, không phải cấu hình đã được chạy hoặc kết quả đã được xác nhận.

Quy trình dự kiến gồm các bước:

1. Kiểm tra dữ liệu, nhãn và ảnh trùng lặp trước khi phân chia tập dữ liệu.
2. Tạo các tập train, validation và test độc lập.
3. Lựa chọn một kiến trúc ViT phù hợp với tài nguyên tính toán và xác định cách khởi tạo trọng số.
4. Tiền xử lý ảnh theo yêu cầu của mô hình được chọn, bao gồm kích thước ảnh và chuẩn hóa pixel.
5. Huấn luyện hoặc fine-tune mô hình trên tập train. Sử dụng tập validation để lựa chọn siêu tham số và cấu hình mô hình.

6. Đánh giá mô hình cuối cùng trên tập test độc lập.

Các chỉ số dự kiến gồm accuracy, precision, recall, macro-F1 và confusion matrix. Việc sử dụng macro-F1 giúp đánh giá hiệu quả theo từng lớp, đặc biệt khi số lượng ảnh giữa các lớp không đồng đều.

Để so sánh với CNN, hai mô hình cần sử dụng cùng định nghĩa nhãn, cùng tập test và cùng quy tắc tính metric. Những khác biệt về kích thước ảnh, augmentation, pretrained weights và cấu hình huấn luyện phải được ghi lại để tránh đưa ra kết luận thiếu cơ sở.

4.4 Quy trình đánh giá

Các metric chỉ có ý nghĩa khi gắn với tập dữ liệu và quy trình đánh giá cụ thể. Đối với hồi quy, cần tách dữ liệu train và test, chỉ khớp mô hình trên train và tính metric cuối cùng trên test. RMSE đo sai số bình phương trung bình theo căn bậc hai, trong khi R^2 đánh giá mức độ giải thích biến thiên của biến mục tiêu theo định nghĩa của metric.

Đối với phân loại ảnh, tập validation được dùng trong quá trình lựa chọn mô hình. Tập test cuối cùng không được sử dụng để lựa chọn epoch hoặc điều chỉnh siêu tham số. Các phép biến đổi ngẫu nhiên chỉ nên được áp dụng cho dữ liệu train; validation và test cần sử dụng quy trình tiền xử lý nhất quán, không có augmentation ngẫu nhiên.

5 Kết quả

5.1 Kết quả CNN

Output đã lưu trong notebook ghi nhận accuracy trên tập được sử dụng làm test xấp xỉ 68,76% và loss khoảng 1,1721 sau 20 epoch.

Đây là kết quả của lần chạy được lưu trong notebook, không phải phép đo độc lập được lặp lại trong quá trình biên soạn báo cáo. Notebook hiện tại sử dụng cùng tập test làm `validation_data` trong quá trình huấn luyện và tiếp tục đánh giá trên tập này. Pipeline ảnh cũng được mô tả là có áp dụng xoay và lật ngẫu nhiên. Vì vậy, kết quả cần được diễn giải thận trọng và chưa thể được xem là đánh giá cuối cùng trên một tập test hoàn toàn độc lập.

Để có kết luận đáng tin cậy hơn, cần tách validation riêng, loại bỏ augmentation ngẫu nhiên khỏi pipeline đánh giá và chạy lại phép đánh giá cuối cùng. Báo cáo cũng cần bổ sung precision, recall, macro-F1 và confusion matrix khi các số liệu này được tính từ lần chạy mới.

5.2 Minh họa hồi quy giá xe

Hình **??** minh họa biểu đồ hồi quy giá xe theo năm sản xuất được lưu trong tài liệu dự án. Ứng dụng Streamlit hiện có khả năng tạo scatter plot của dữ liệu được lựa chọn và vẽ đường hồi quy tương ứng.

Do chưa có kết quả đánh giá hồi quy trên tập test độc lập được cung cấp trong phiên bản báo cáo này, chưa đưa ra kết luận định lượng về khả năng dự đoán giá xe trên các tin đăng mới. Các metric tính trên dữ liệu huấn luyện chỉ phản ánh mức độ phù hợp của mô hình với dữ liệu đã dùng để khớp.

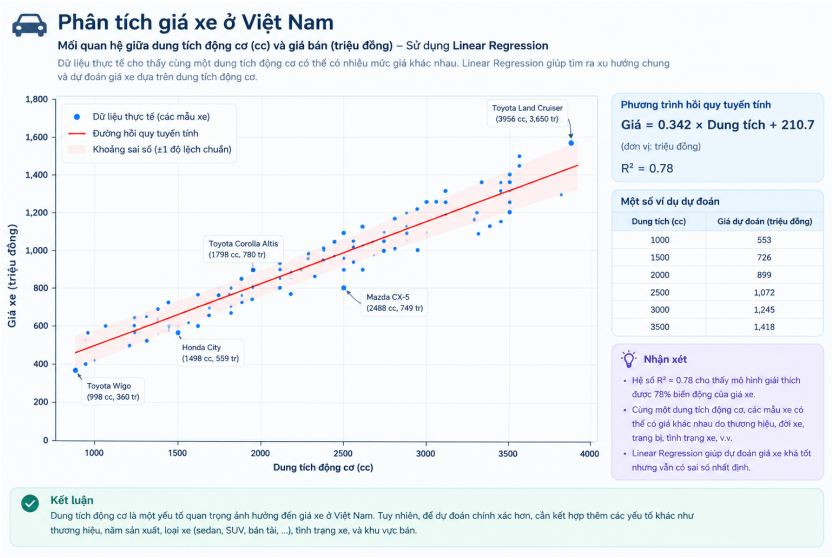


Fig. 1. Minh họa phân tích giá xe theo năm sản xuất.

5.3 Trạng thái thực nghiệm của Vision Transformer

Vision Transformer hiện mới ở giai đoạn đề xuất phương pháp. Mô hình chưa được triển khai, huấn luyện hoặc đánh giá trong dự án. Do đó, chưa có số liệu thực nghiệm để báo cáo accuracy, loss, macro-F1 hoặc thời gian huấn luyện của ViT.

Việc so sánh CNN với ViT chỉ có thể thực hiện sau khi hoàn tất quá trình triển khai và đánh giá trên cùng một tập test độc lập. Không thể kết luận ViT tốt hơn hoặc kém hơn CNN dựa trên thiết kế phương pháp khi chưa có kết quả thực nghiệm.

6 Thảo luận và giới hạn

6.1 Giới hạn của Linear Regression

Mô hình hồi quy minh họa sử dụng một biến đầu vào là năm sản xuất. Do đó, mô hình không thể biểu diễn đầy đủ ảnh hưởng của tình trạng xe, số kilomet đã đi, xuất xứ, phiên bản và các yếu tố khác đến giá.

RMSE và R^2 của script hiện được tính trên dữ liệu đã dùng để khớp mô hình. Ứng dụng Streamlit cũng hiển thị mức độ phù hợp trên dữ liệu train. Vì chưa có tập validation hoặc test độc lập, các metric này chưa phản ánh đầy đủ khả năng dự đoán trên dữ liệu mới.

Ngoài ra, tên cột năm trong CSV được mô tả là `Năm sản xuất`, trong khi script `linear_regression.py` được ghi nhận là truy cập `Năm sản xuất:`. Sai khác này cần được đồng bộ trước khi chạy lại script để tránh lỗi truy cập cột.

Việc chuyển các cột văn bản sang số bằng cách trích xuất số đầu tiên cũng là một giới hạn. Cách làm này không bảo đảm giữ nguyên ý nghĩa của các thuộc tính phân loại và có thể tạo ra đặc trưng không phù hợp cho mô hình hồi quy.

6.2 Giới hạn của CNN

Kết quả accuracy 68,76% và loss 1,1721 là kết quả được lưu trong notebook, nhưng quy trình đánh giá hiện tại chưa tách biệt hoàn toàn validation và test. Việc sử dụng tập test trong quá trình huấn luyện có thể ảnh hưởng đến tính độc lập của đánh giá cuối cùng.

Bên cạnh đó, augmentation ngẫu nhiên trong pipeline đánh giá có thể khiến kết quả phụ thuộc vào phép biến đổi được áp dụng. Cần kiểm tra phân bố số lượng ảnh theo lớp, ảnh trùng lặp và những trường hợp dự đoán sai để hiểu rõ hơn hiệu quả của mô hình.

6.3 Giới hạn và kế hoạch đối với ViT

ViT chưa được triển khai nên chưa thể đánh giá chi phí tính toán, hiệu quả phân loại hoặc khả năng tổng quát hóa trên bộ dữ liệu hiện có. Đây là giới hạn về trạng thái triển khai, không phải bằng chứng cho thấy phương pháp có hiệu quả thấp hoặc cao.

Hướng phát triển là fine-tune một mô hình ViT pretrained, sau đó đánh giá trên cùng tập test với CNN. Việc so sánh nên xem xét không chỉ accuracy mà còn macro-F1, confusion matrix, thời gian huấn luyện và số lượng tham số. Các kết quả chỉ được đưa vào báo cáo sau khi thực nghiệm thực sự được hoàn thành.

6.4 Khả năng tái lập

Để tăng độ tin cậy, cần lưu lại phiên bản thư viện, cấu hình mô hình, seed, cách chia dữ liệu và metric của từng lần chạy. Với bài toán phân loại ảnh, cần bảo đảm tập test không được sử dụng trong quá trình lựa chọn mô hình. Với bài toán hồi quy, cần lưu lại các bước tiền xử lý và đánh giá trên dữ liệu độc lập.

Các giao diện Streamlit và Gradio hỗ trợ minh họa khả năng sử dụng của dự án, nhưng sự tồn tại của giao diện không tự nó chứng minh hiệu năng dự đoán hoặc khả năng tổng quát hóa của mô hình.

7 Kết luận và hướng phát triển

Dự án PPR501 Car Analysis kết hợp các kỹ thuật Machine Learning và Deep Learning cho hai nhóm bài toán trong lĩnh vực ô tô. Linear Regression được sử dụng để khảo sát mối quan hệ giữa năm sản xuất và giá xe, trong khi CNN được triển khai để phân loại hình ảnh thuộc bảy nhóm xe. Streamlit cung cấp giao diện tương tác với dữ liệu giá, còn Gradio hỗ trợ trình diễn khả năng dự đoán ảnh.

Notebook CNN hiện ghi nhận accuracy khoảng 68,76% và loss khoảng 1,1721 sau 20 epoch. Tuy nhiên, do quy trình đánh giá còn những hạn chế, kết quả cần được xác minh lại trên tập test độc lập. Phần hồi quy cũng cần bổ sung đánh giá trên dữ liệu chưa được dùng để huấn luyện trước khi đưa ra kết luận về khả năng dự đoán giá xe mới.

Vision Transformer được xác định là hướng mở rộng cho bài toán phân loại ảnh xe. Vì mô hình chưa được triển khai, báo cáo chưa đưa ra kết luận về hiệu năng tương đối giữa ViT và CNN. Các bước tiếp theo gồm chuẩn hóa dữ liệu, hoàn thiện quy trình đánh giá, triển khai ViT pretrained và so sánh hai kiến trúc trên cùng một tập test.

Những cải tiến này sẽ giúp dự án chuyển từ một hệ thống minh họa các phương pháp Machine Learning sang một quy trình thực nghiệm có thể tái lập và có cơ sở đánh giá rõ ràng hơn.

Acknowledgments. Nhóm xin cảm ơn giảng viên Nguyễn Xuân Sâm đã hướng dẫn nhóm trong học phần PPR501.

Disclosure of Interests. Nhóm không có xung đột lợi ích cần công bố.

References

1. Kaggle: Automobile Dataset (Vietnam car prices). https://www.kaggle.com/datasets/qucvinhdng/automobile-dataset Truy cập ngày 18 tháng 10 năm 2026.
2. Kshitij: Car Images Classification using CNN – Dataset. Kaggle. https://www.kaggle.com/code/kshitij192/car-images-classification-using-cnn/data Truy cập ngày 18 tháng 10 năm 2026.
3. Nhóm PPR501: PPR501 Car Analysis. GitHub repository. https://github.com/ptnghia3502/PPR501-car-analysis Truy cập ngày 18 tháng 10 năm 2026.
4. Dosovitskiy, A., et al.: An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. In: International Conference on Learning Representations (ICLR) (2021).
5. Montgomery, D.C., Peck, E.A., Vining, G.G.: Introduction to Linear Regression Analysis. 5th edn. Wiley (2012).